רותם דאר – 311352934
יוגב יוסף – 312273410

כריית מידע - פרויקט חלק 1

שלב 1 - Data information

הצגת המידע:

תחילה, הצגנו את המידע על ידי הפקודה df.head() . ראינו שיש כ30517 נתוני מידע ולכל אחד יש כ20 פיצ'רים.

תיקנו את הערכים שהיו כתובים כ – unknown ל np.nan והצגנו את df.info():

```
df.info()

<class 'pandas.core.frame.DataFrame'>
Int64Index: 30517 entries, 512491 to 516748
Data columns (total 20 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   status            30517 non-null  object
 1   age               30517 non-null  int64
 2   n_child           10697 non-null  object
 3   education         29273 non-null  object
 4   profession        30324 non-null  object
 5   device            21646 non-null  object
 6   account_balance   30517 non-null  int64
 7   loan              30517 non-null  bool
 8   mortgage          30517 non-null  bool
 9   credit            30517 non-null  bool
 10  positive          30517 non-null  bool
 11  campaign_type     30517 non-null  object
 12  consent           30517 non-null  bool
 13  n_contact         30517 non-null  int64
 14  l_date            30517 non-null  object
 15  l_call_duration   30517 non-null  int64
 16  p_outcome         5574 non-null   object
 17  n_p_contact       30517 non-null  int64
 18  p_days            30517 non-null  int64
 19  subscribed        30517 non-null  bool
dtypes: bool(6), int64(6), object(8)
memory usage: 3.7+ MB
```

יש 6 פיצ'רים מסוג int.

שאר הפיצ'רים הם מסוג object\bool.

לפי מבט ראשוני על המידע ניתן לראות כי לפיצ'רים הבאים חסרים ערכים:

- n_child - missing 19,820 values.
- education - missing 1,244 values.
- profession - missing 193 values.
- device - missing 8,871 values.
- p_outcome - missing 24,943 values.

בנוסף פיצלנו את ה Data frame ל3 סוגים שונים:

1. target - the target value of the data - 'Subscribed'.
2. num_data - the numeric data. (All the int features)
3. nom_data - the nominal data. (The rest of the features object\bool).

שלב 2 - Data statistics & Visualization

Numeric Data:

הצגת המידע הסטטיסטי:

```
num_data.describe()
```

	age	account_balance	n_contact	l_call_duration	n_p_contact	p_days
count	30517.000000	30517.000000	30517.000000	30517.000000	30517.00000	30517.000000
mean	40.873546	1228.707966	2.769604	233.294262	0.58397	40.320706
std	10.591058	2738.410757	3.085730	232.690931	2.48213	100.489272
min	18.000000	-7207.000000	1.000000	2.000000	0.00000	-1.000000
25%	33.000000	74.000000	1.000000	95.000000	0.00000	-1.000000
50%	39.000000	411.000000	2.000000	164.000000	0.00000	-1.000000
75%	48.000000	1278.000000	3.000000	286.000000	0.00000	-1.000000
max	95.000000	91924.000000	63.000000	4428.000000	275.00000	871.000000

הצגת הגרפים:

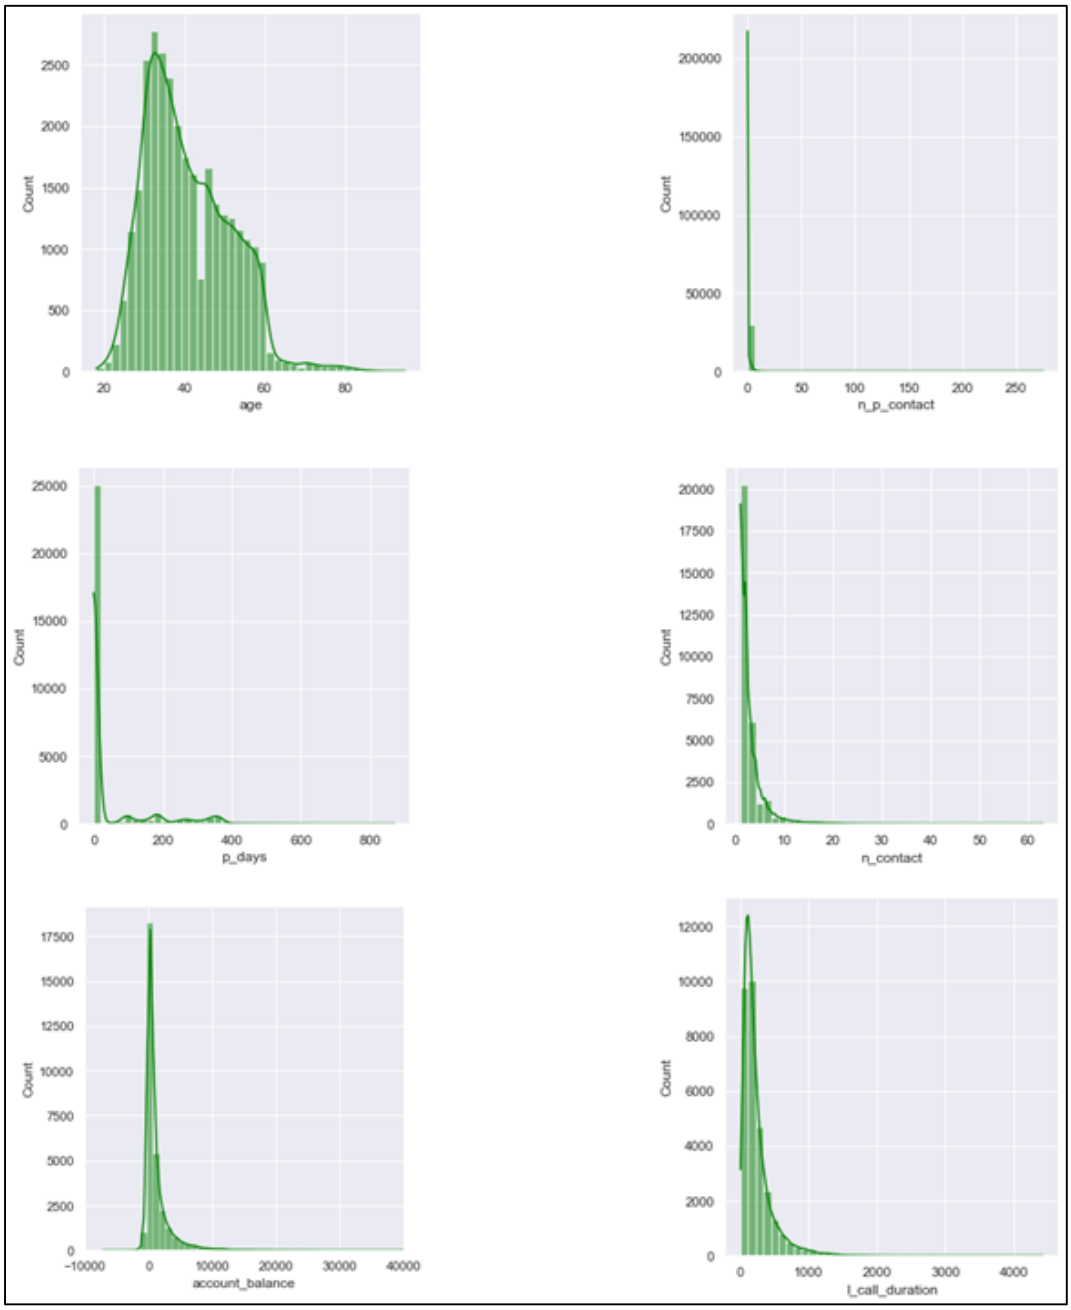
Count
age
n_p_contact
p_days
n_contact
account_balance
l_call_duration

חישוב Skewness:

Feature	Skewness
Age	0.6962
P_days	2.6168
L_call_duration	3.3062
N_contact	4.7919
Account_balance	8.3480
N_p_contact	48.0634

ניתן לראות מהגרפים וטבלת ה Skewness שמסודרת בסדר עולה, כי age מתפלג בצורה שהכי קרובה להתפלגות אחידה (הכי סימטרי) לעומת n_p_contact שמתפלג בצורה הכי לא סימטרית.
כמו כן, לשאר הפיצ'רים הנומרים ששונים מ age, יש ערכים חריגים (הרוב נמצא באיזור 0 ומעט בערכים הגדולים מ – 0).
טיפלנו בחריגים בחלק של – Data transformation.

חקירת הפיצ'רים הרלוונטים בהתאם לערך המטרה – subscribed:

Age vs subscribed

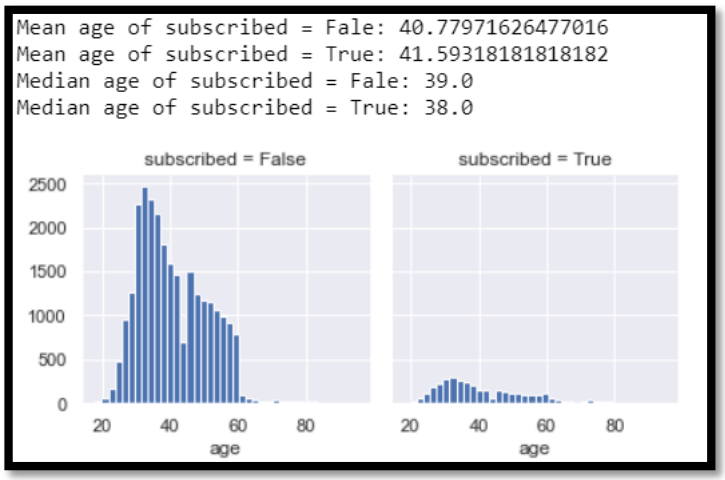

לא ניתן ללמוד יותר מדי מהגיל הממוצע או החציון של הגילאים שבהם הסכימו לרכוש ביטוח. מכיוון שההתפלגות של הגרפים יצאה זהה ובנוסף הממוצעים + החציונים יצאו זהים.

L_call_duration vs subscribed

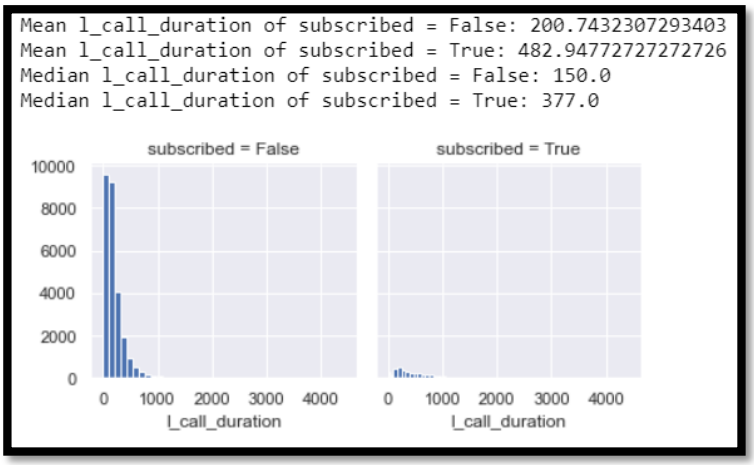

ניתן לראות כי אורך השיחה השפיע על רכישת הביטוח – ככל שאורך השיחה עלה ככה יותר אנשים רכשו ביטוח, אורך שיחה ממוצע של 482 וחציון של 377.
הסקנו יותר מסקנות לפיצ'ר זה ב scatter plot.

account_balance vs subscribed

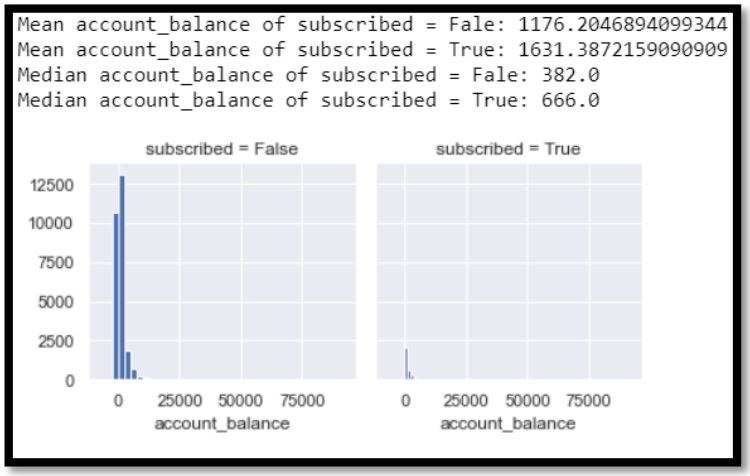

ניתן לראות כי ממוצע ההכנסה השנתית השפיע על רכישת הביטוח – ככל שממוצע ההכנסה השנתית היה גבוה יותר ככה יותר אנשים רכשו ביטוח.
לא הצלחנו ללמוד מההשפעה של מהממוצע של ממוצע ההכנסה השנתית (כנראה בגלל שיש יותר ערכים קיצוניים), אך ניתן ללמוד מהחציון שהוא 666 - ככל שלאנשים היה יותר כסף הם בסוף רכשו ביטוח.

n _contact vs subscribed

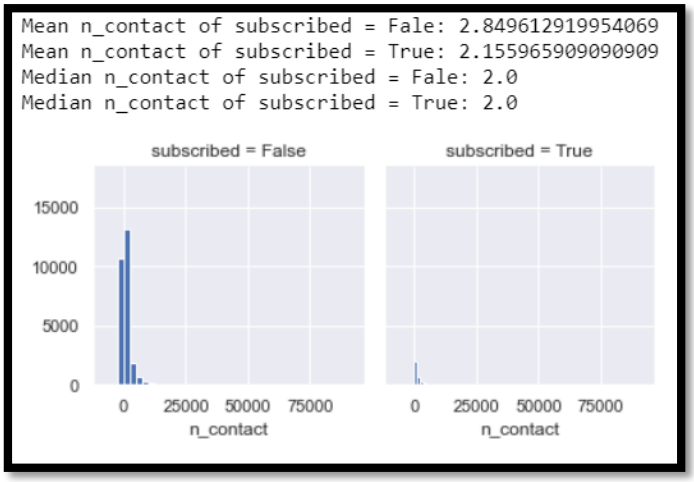

לא ניתן ללמוד יותר מדי ממספר השיחות שבוצעו ללקוח במהלך הקמפיין הנוכחי – מהו המספר המתאים ביותר בכדי שלקוח ירכוש בסוף ביטוח. מכיוון ש הממוצעי שיחות וגם ה median של הלקוחות שרכשו בסוף ביטוח ולא רכשו יצאו זהים, ובנוסף ההתפלגות של הגרפים זהה.

n_p_contact vs subscribed

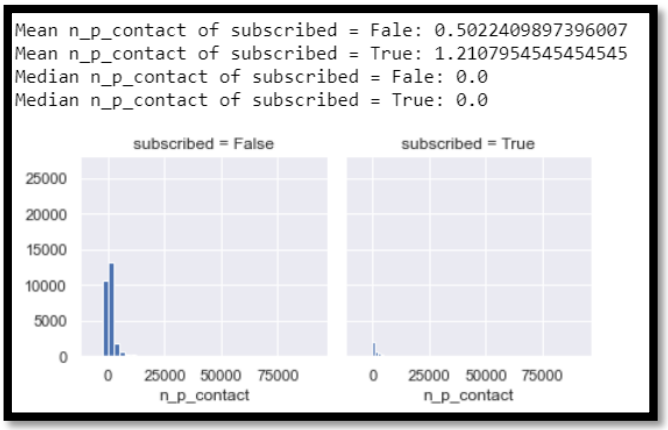

ניתן לראות כי מספר הפעמים שהתקשרו לכל לקוח בקמפיין הקודם השפיע על רכישת הביטוח.
ככל שמספר הפעמים שהתקשרו לכל לקוח בקמפיין הקודם היה לפחות פעם אחת, ככה זה השפיע עליו לרכוש ביטוח בקמפיין הנוכחי.
(המסקנה הזו נבעה מהממוצעים, אך לא ניתן ללמוד מהחציון).

P_days vs subscribed

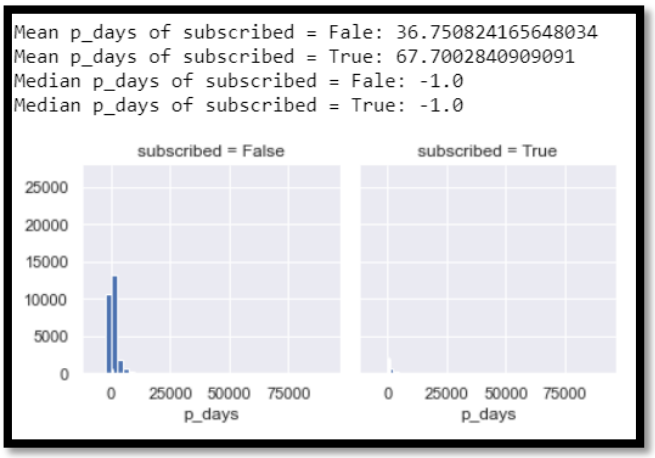

עבור p_days הסקת המסקנות הייתה מסובכת יותר, כי קיימים ערכים ב data שעבורם p_days == -1.
בהמשך חקירת המידע הבנו שערכים אלו הם עבור אנשים שלא השתתפו בקמפיין הקודם.
אז כרגע על פי הגרפים הללו ניתן לראות שעבור הגרף שבו subscribed == False לקוחות שדיברו איתם לפני הרבה זמן מהקמפיין הקודם לא רכשו ביטוח.

Nominal Data:

הצגת המידע הסטטיסטי:

	status	n_child	education	profession	device	loan	mortgage	credit	positive	campaign_type	consent	l_date	p_outcome
count	30517	10697	29273	30324	21646	30517	30517	30517	30517	30517	30517	30517	5574
unique	3	4	3	11	2	2	2	2	2	1	2	308	3
top	married	1	master	engineer	cellular	False	True	False	True	phone call	False	15-May	failure
freq	18414	3058	15622	6538	19718	25632	17055	29987	28059	30517	26997	782	3330
Percent of top value	60.34	10.021	51.191	21.424	64.613	83.993	55.887	98.263	91.945	100.0	88.465	2.563	10.912

ראשית, ניתן לראות שיש 13 פיצ'רים. אלו הם הפיצ'רים מהסוג שלא integer כלומר bool\object.

שמנו לב שקיימת בעיה עם העמודה l_date – פעם אחרונה שיצרו קשר עם הלקוח.
העמודה מוצגת בשילוב של מספר יום + חודש: day_month.
החלטנו ליצור עמודה חדשה – month_l_date ולחקור את פיצ'ר זה ברמת החודש, ולא לחקור לרמת היום, מכיוון שאנו חושבים שכך יהיה יותר קל לנהל את ה data ולבצע חישובים.
כמו כן, לא הרסנו את העמודה המקורית שאם נבין שהחלטה זו לא יעילה עדיין נוכל להשתמש בעמודה l_date.

תחילה הצגנו כל פיצ'ר על ידי גרף.

רותם דאר – 311352934
יוגב יוסף – 312273410

הצגת הגרפים:

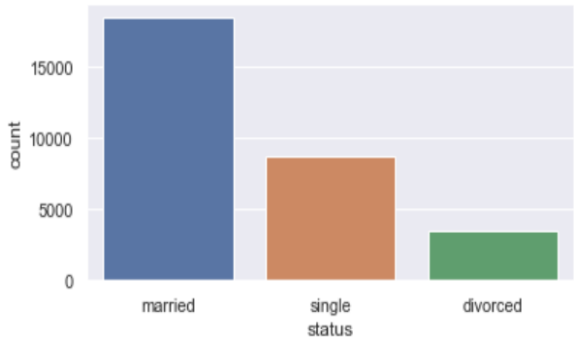

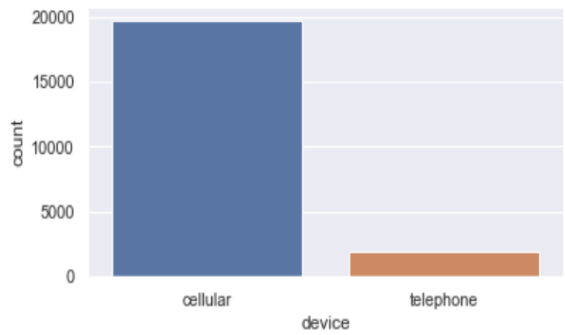

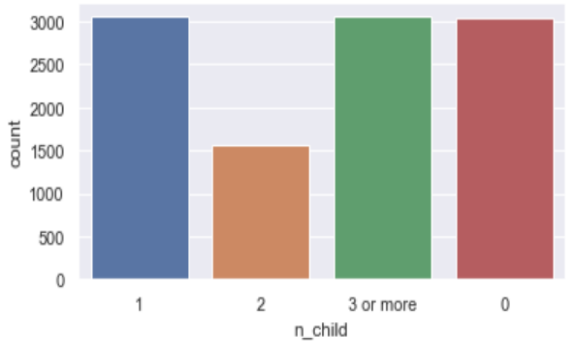

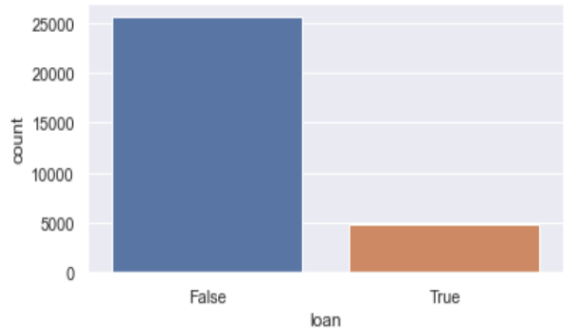

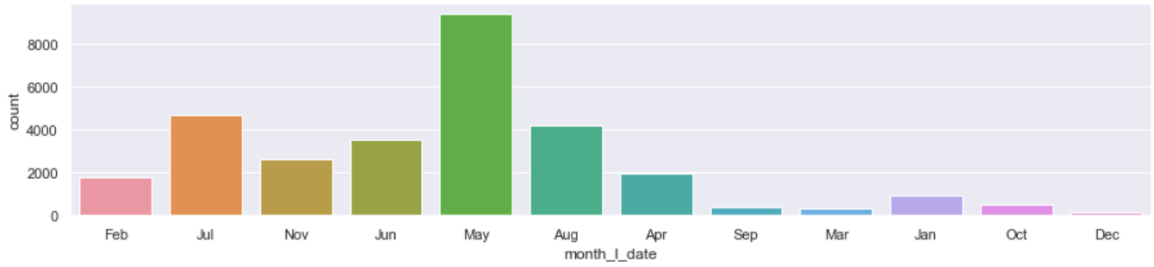

רותם דאר – 311352934
יוגב יוסף – 312273410

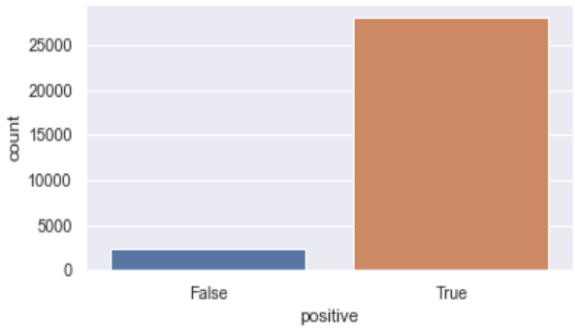

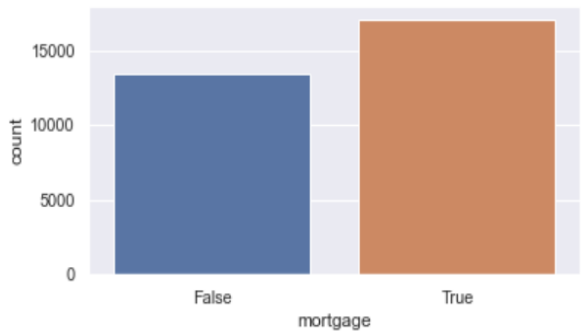

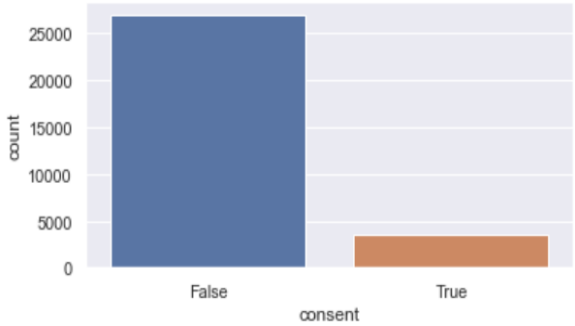

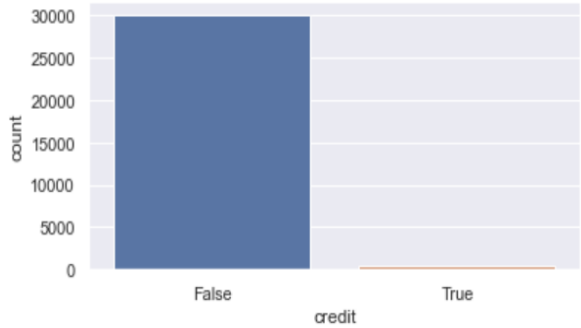

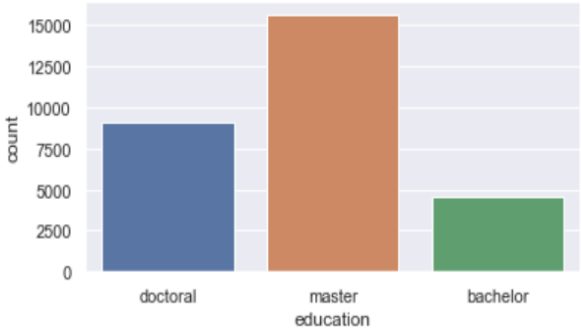

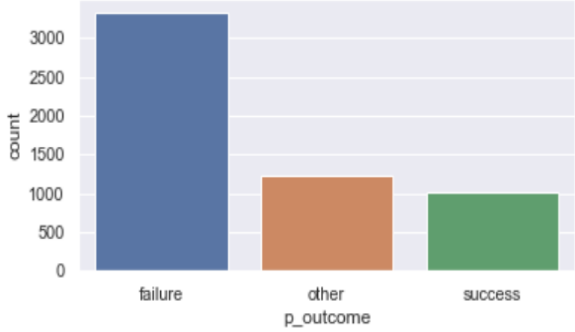

<u>מסקנות:</u>

- ניתן לראות כי רוב המשתתפים נשואים.
- ניתן לראות כי רוב המשתתפים עם רמת השכלה master.
- ניתן לראות כי רוב המשתתפים לא נמצאים במינוס בחשבון הבנק.
- ניתן לראות כי לרוב המשתתפים יש אשראי.
- ניתן לראות כי רוב המשתתפים לא לקחו הלוואה.
- בn_child ובp_outcome יש הרבה ערכים חסרים ולכן לא ניתן להסיק מסקנות.
- ניתן לראות שרוב הפניות למשתתפים התבצעו לטלפון האישי (השתמשנו בעובדה זו בתהליך ה pre_processing).

- לא הוספנו גרף עבור campaign type מכיוון שהוא 100% טלפוני (בהמשך מחקנו את עמודה זו).
- לא הוספנו גרף עבור consent מכיוון שבהמשך מחקנו עמודה זו (והסברנו מדוע).
- ניתן לראות כי לרוב המשתתפים פעם האחרונה שיצרו איתם קשר היה בחודש מאי.

Scatter plot:

בחרנו לעשות scatter plot עבור l_call_duration vs subscribed.

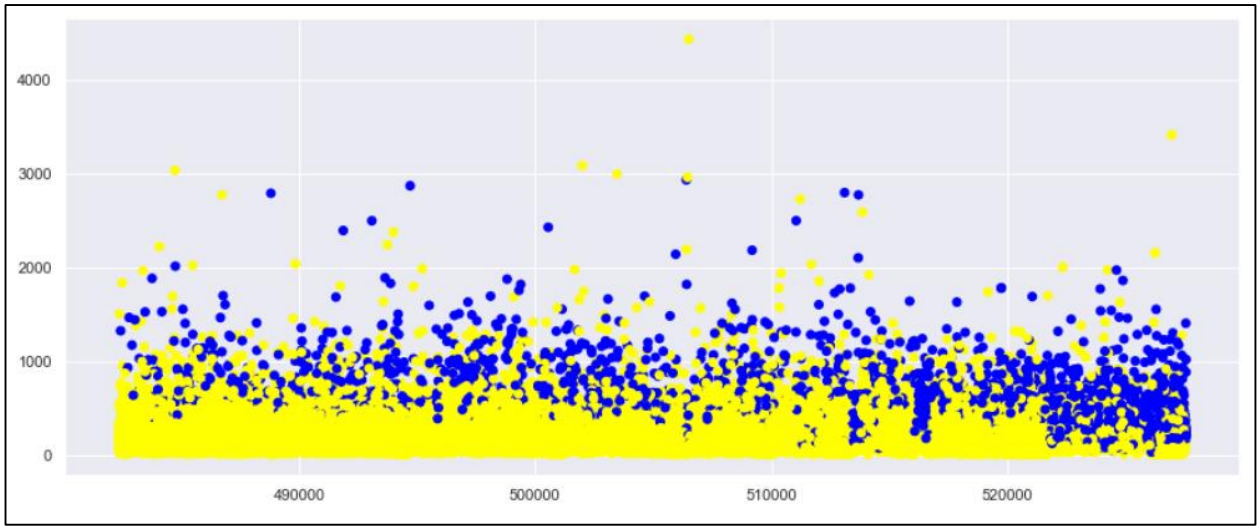

Subscribed → False = yellow
Subscribed → True = blue

- אנו משערים כי הזמן נתון בשניות.

ניתן לראות בצורה ברורה כי רוב השיחות שלא היו מספיק ארוכות (בין 0 ל – 1000 שניות) באמת לא רכשו ביטוח בסופן, ולעומת זאת ניתן לראות כי שיחות ארוכות יותר (מעל 1000) הסתיימו ברכישת ביטוח.
נתון מעניין נוסף שניתן ללמוד מגרף זה שהאחוזים של מי שרכש ביטוח בשיחות שאורכן גדול מ2000 הוא לא טוב (אזור ה50%), כלומר צריך לשקול להפסיק לנסות לשכנע בשיחות שאורכן מתארך מעל ל2000 מבחינת אחוזים.

בנוסף רואים כי האחוזים של מי שרכש ביטוח בשיחות שאורכן 1000-2000 היה מאוד גבוה.

Box plot:

age - status	age - education	L_call_duration - education	L_call_duration - loan

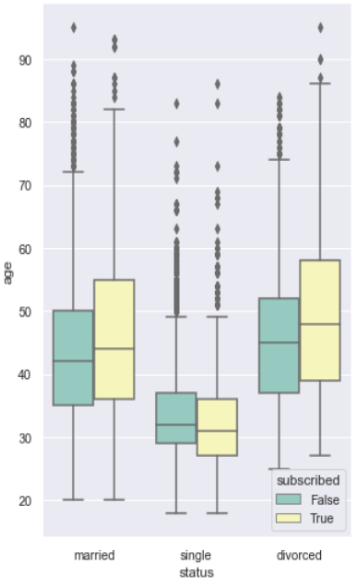

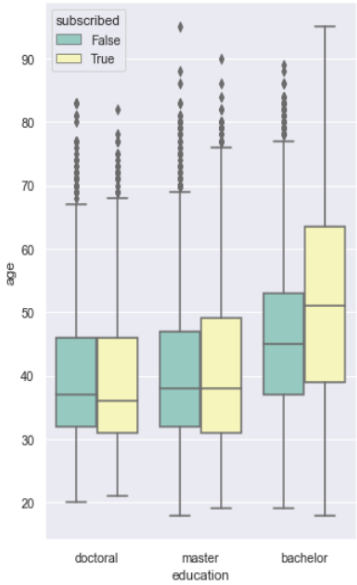

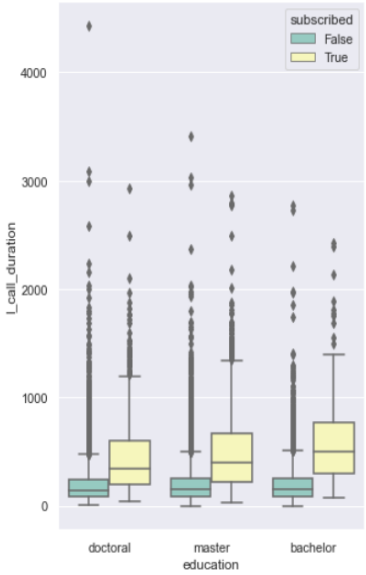

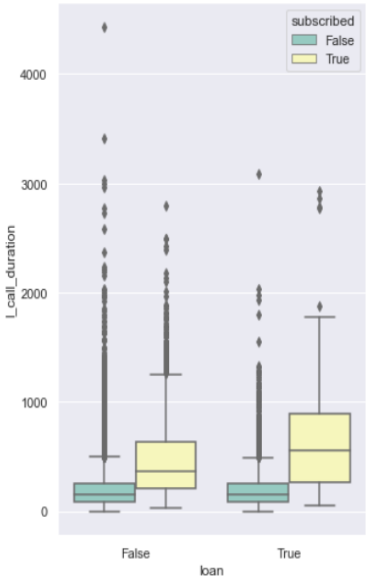

- age-status – ניתן לראות שמי שלא נשוי/גרוש שאין שינוי בגיל בין מי שרכש ביטוח או לא רכש ביטוח, לעומת זאת בנשואים/גרושים ניתן לראות כי המבוגרים יותר באותה קבוצה רכשו ביטוח.
- age vs education – ניתן לראות שמי שמבוגר יותר כדי שיהיה יותר סיכוי שירכוש ביטוח עדיף למצוא מבוגר שעושה תואר ראשון, לעומת זאת מי שצעיר כדי שיהיה יותר סיכוי שירכוש ביטוח עדיף למצוא צעיר שעושה דוקטור.
- l_call_duration vs education – ניתן לראות שללא קשר לרמת השכלה ככל שהשיחה התארכה יותר כך זה השפיע על רכישת הביטוח.
- l_call_duration vs loan – ניתן לראות שללא קשר ללקיחת הלוואה ככל שהשיחה התארכה יותר כך זה השפיע על רכישת הביטוח.

Target:

הצגת התפלגות ערך המטרה – subscribed:

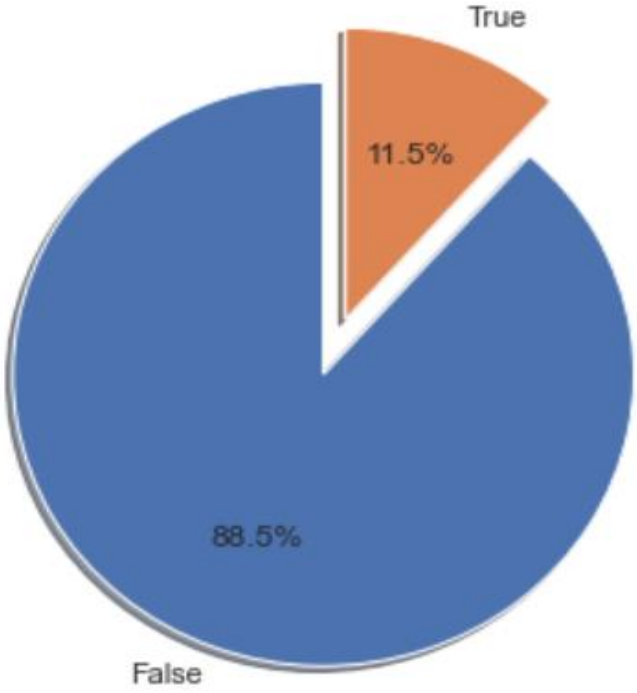

ניתן לראות כי רוב המשתתפים לא רכשו את הביטוח בסופו של דבר.

שלב 3 - Data correlation

המרנו את הערכים הנומינליים לערכים נומריים ע"י הפקודה cat.codes ואז חישבנו את הקורלציה בין כל הפיצ'רים:

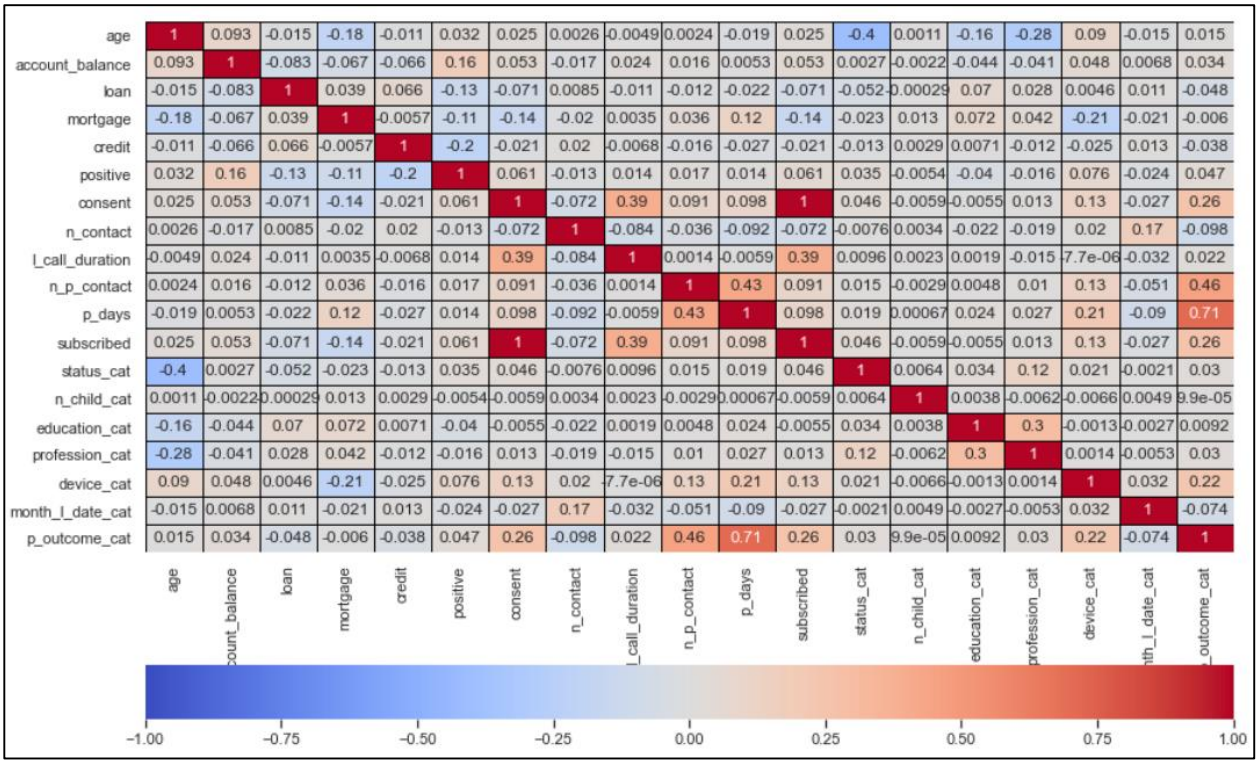

- ניתן לראות כי בין רוב הפיצ'רים אין קורלציה גבוה (לא הפוכים ולא מתואמים).
- לפיצ'ר p_outcome יש קורלציה יחסית גבוהה עם n_p_contact – 0.46.
- לפיצ'ר p_outcome יש קורלציה מאוד גבוהה עם p_days – 0.71. השתמשנו בקורלציה הזאת על מנת להשלים את הערכים החסרים בp_outcome.
- ל subscribed ו consent יש קורלציה של 1, בהמשך פירטנו מדוע מחקנו את עמודה זו.

שלב 4 - Data cleaning

Pre-Processing

- הערה: בתהליך זה לא מחקנו את העמודות המקוריות, הוספנו עמודות חדשות בשם: xxxxx_Pre_Proc (כאשר – xxxxx הוא השם של הפיצ'ר) שבהם מילאנו את הערכים החסרים כתוצאה מהתהליך.

ניתן לראות בקוד כי בתחילה בדקנו באילו שורות יש הכי הרבה ערכים חסרים בפיצ'רים (כלומר יש הכי הרבה null) וראינו כי המקסימום ערכי null בשורה הוא 4.
יש 33 שורות כאלו, ומכיוון שמדובר ב 4 פיצ'רים null מתוך 20 החלטנו כי אנחנו לא מוחקים את השורות האלו, כי יש 16 פיצ'רים שיש להם ערכים וזו כמות די גבוהה.
כעת נעבור על הפיצרים שיש בהם ערכים חסרים ונמלא אותם בשיטה המתאימה ביותר.

N_child:

לפיצ'ר זה חסרים המון ערכים לכן שיטת החציון/ממוצע לא נכונה פה.
בנוסף השיטה למלא לפי הערך שיש לו רוב גם לא נכונה פה מכיוון שזה לא רוב המידע.
כמו כן, לפיצ'ר זה אין קורלציה גבוהה במיוחד עם פיצ'ר אחר אז גם לא ניתן לתקן לפי קורלציה.
כדי לבדוק האם יש עוד משהו שאפשר לעשות, מחקנו את כל השורות שבהן לפיצ'ר זה אין ערך ולאחר מכן בדקנו האם יש קורלציה עם המידע, אך גם פה גילינו שאין קורלציה גבוהה.
לכן אנו מבינים שפיצ'ר זה לא תורם לנו מספיק מידע ובסופו של דבר החלטנו למחוק אותו.

Education:

לפיצ'ר זה קיימים 1244 שורות שחסרים בו ערכים.
1244 זה 4% מסך השורות, ולדעתינו זוהי כמות יחסית גבוה.
לפיצ'ר זה אין קורלציה גבוהה עם פיצ'ר אחר (למעט קורלציה – 0.29 עם profession
אך בעייתי לעבוד עם פיצ'ר זה כי גם לו חסרים ערכים).
לכן בחרנו לתקן פיצ'ר זה ע"י שיטה של מרחק אוקלידי מינימלי.

Filling missing values using similarity between objects

In [45]:
```
education_miss = df[df['education'].isnull()].drop(['status','n_child','education','profession','device','month_l_date','l_date',
education_exist = df[df['education'].notnull()].drop(['status','n_child','education','profession','device','month_l_date','l_date
```

In [46]:
```
ary = scipy.spatial.distance.cdist(education_miss, education_exist, metric='euclidean')
```

In [47]:
```
df.groupby(['education','education_cat']).size()
```

Out[47]:
```
education  education_cat
bachelor   0                4590
doctoral   1                9061
master     2               15622
dtype: int64
```

In [48]:
```
df['education_Pre_Proc'] = df['education']
for i,j in enumerate(education_miss.index):
    value= int(df.loc[education_exist[ary[i]==ary[i].min()].index]['education_cat'].mean())
    if value == 0:
        df.loc[j,'education_Pre_Proc'] = 'bachelor'
    elif value == 1:
        df.loc[j,'education_Pre_Proc'] = 'doctoral'
    else:
        df.loc[j,'education_Pre_Proc'] = 'master'
```

יצרנו 2 data frame חדשים:
Education_miss: שבו קיימים כל הערכים הנומרים שיש להם null ב education.
Education_exist: שבו קיימים כל הערכים הנומרים שאין להם null ב education.
יצרנו מערך ary שמכיל את המרחקים האוקלידים בין שני ה data frames.
ובעזרתו, ובעצרת מציאת המרחקים הקצרים מילאנו את הערכים החסרים ב education.
לסיום הצגנו את שני הגרפים:
Education – העמודה המקורית לפני pre processing.
Education_pre_proc – העמודה לאחר ה pre processing.

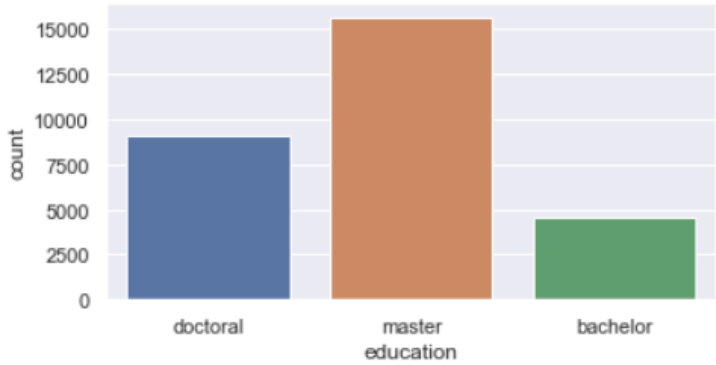

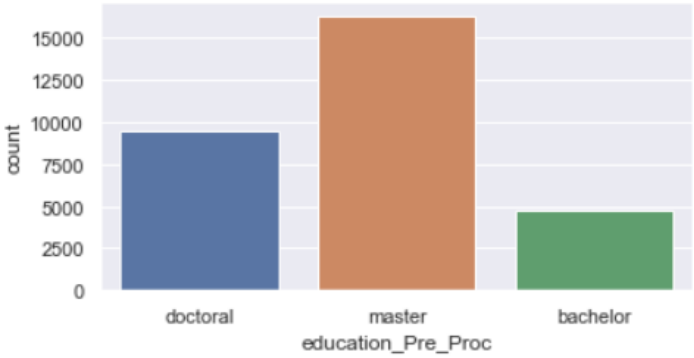

ניתן לראות כי אחרי מילוי הערכים החסרים שמרנו על ההתפלגות הצפויה.

Profession:

תחילה בדקנו כמה ערכים חסרים. חסרים 193 ערכים שזה 0.63% מהמידע.
בגלל שיש ממש מעט ערכים חסרים החלטנו לתקן פיצ'ר זה לפי החציון.

```
In [52]: df.groupby(['profession','profession_cat']).size()

Out[52]: profession     profession_cat
         accountant     0                1491
         architect      1                 833
         engineer       2                6538
         manager        3                6458
         retired        4                 988
         scientist      5                5138
         self-employed  6                 882
         student        7                1096
         teacher        8                2759
         technician     9                3503
         unemployed     10                638
         dtype: int64

In [53]: df['profession_Pre_Proc'] = df['profession_cat']
         df['profession_Pre_Proc'].replace(-1,np.nan,inplace = True)

In [54]: df['profession_Pre_Proc'].median()

Out[54]: 3.0

In [55]: df['profession_Pre_Proc'].mean()

Out[55]: 4.480543463922965

In [56]: #Filling the null values with the median
         df['profession_Pre_Proc'] = df['profession_Pre_Proc'].fillna(value=df['profession_Pre_Proc'].median())

In [57]: # Changing the cat.codes back to the origin code:
         for i, row in df.iterrows():
             if df.loc[i,'profession_Pre_Proc'] == 0.0:
                 df.loc[i,'profession_Pre_Proc'] = 'accountant'
```

עשינו קטלוג של כל הערכים ולאחר מכן חישבנו את החציון והממוצע ומילאנו את כל הערכים החסרים בחציון (בגלל שהחציון והממוצע קרובים יחסית), לאחר מכן עשינו תיקון מהערך הנומרי לערך הנומינלי בהתאמה.

הצגנו שני הגרפים של profession לאחר התיקון ולפני התיקון:

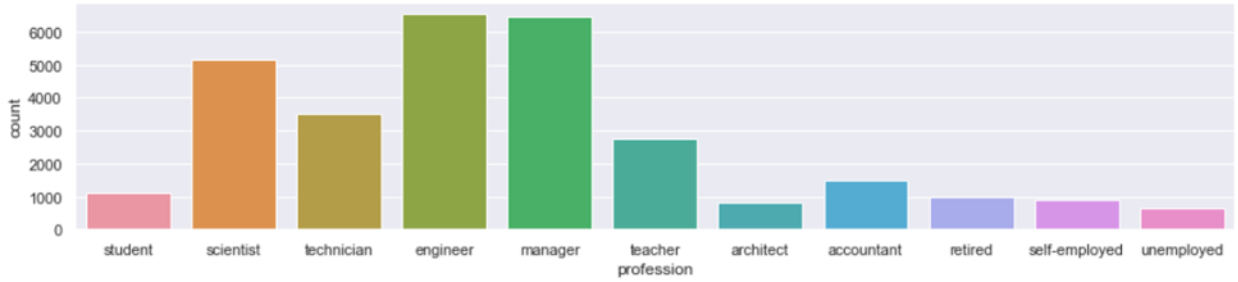

ניתן לראות ש engineer ו manager עדיין מהווים מקסימום מהערכים.

Device:

קיימים 8871 שורות שבהם חסר הערך device.
בנוסף, cellular מהווה 65% מהערכים בעמודת ה device.

בגלל שרוב הערכים הם cellular מתוך 2 ערכים החלטנו למלא את כל הערכים החסרים בערך cellular.

הצגת הגרף של device לפני התהליך ואחרי התהליך:

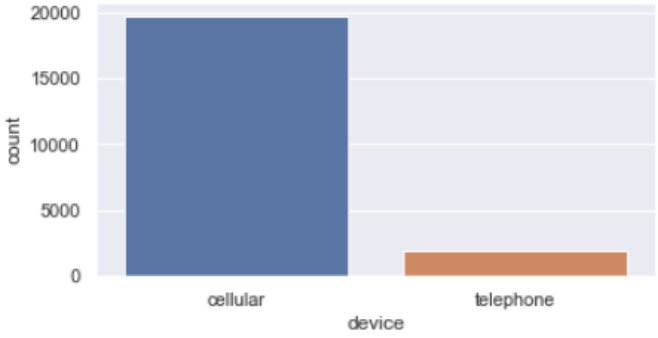

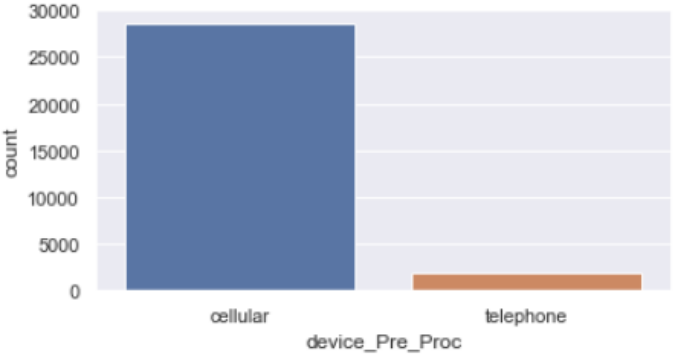

P_outcome:

לפיצ'ר זה חסרים המון ערכים – קיימים 24943 שבהם חסר ערך של p_outcome.
תחילה חשבנו שאולי כדאי למחוק את העמודה הזו כי ב 81% מהdata חסר ערך של p_outcome, אך לאחר בדיקה מעמיקה ניתן לראות כי יש קורלציה מאוד גבוה בין פיצ'ר זה לבין p_days – קורלציה של 0.7 ובנוסף יש ל p_outcome קורלציה של 0.26 עם הערך מטרה subscribed.
ביצענו בדיקה נוספת להשוואת הערכים בין p_outcome_cat ל p_days:

```
In [68]: df.groupby(['p_outcome_cat','p_days']).size()

Out[68]: p_outcome_cat  p_days
         -1             -1        24940
                         98            1
                         168           1
                         528           1
          0              1             3
                                   ...
          2              550           1
                         555           1
                         561           1
                         651           1
                         771           1
         Length: 1064, dtype: int64
```

ניתן לראות כי ב 24940 מקומות שבהם p_outcome_cat הוא 1- (כלומר null) אז p_days הוא 1- . שזה כמעט כל ה data שחסר בו p_outcome.
לכן הבנו שככל הנראה לאנשים שלא השתתפו בקמפיין הקודם הוחלט לשים ב p_outcome ערך – unknown וגם ב p_days שמו 1- זאת אומרת שניתן להסיק כי כל הערכים החסרים הם בעצם אנשים אשר לא השתתפו בקמפיין הקודם.
ומכיוון שיש קורלציה עם הערך מטרה, החלטנו לא לוותר על העמודה הזו ולמלא את כל הערכים החסרים בערך חדש missVal.

הצגת העמודה p_outcome_Pre_Proc לאחר התהליך:

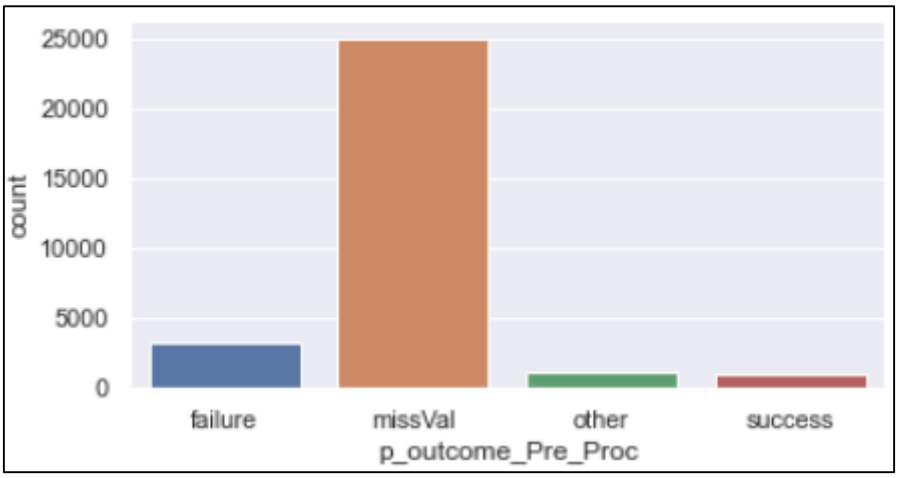

Outliers

בהסתכלות על הגרפים של הערכים הנומרים ובנוסף מניתוח ה skewness ניתן לראות שלמעט age המתפלג קרוב להתפלגות אחידה, לשאר הערכים יש הרבה ערכים קיצוניים המשפיעים על ההתפלגות.
לכן החלטנו לשאר הערכים הנומרים לבצע ניתוח של הערכים הקיצוניים ולשנות אותם בהתאם.

n_p_contact:

בניתוח של הגרף שעשינו ניתן לראות כי רוב מוחלט של הערכים הרלוונטיים לפיצ'ר זה קטנים מ15 (קיימים רק 78 שורות שבהם יש ערך n_p_contact הגדול מ 15 והם מהווים 0,25% מהdata), לכן החלטנו להמיר את כל הערכים שגדולים מ15 (שזה 419 ערכים) לערך 15.

n_p_contact לאחר השינוי:

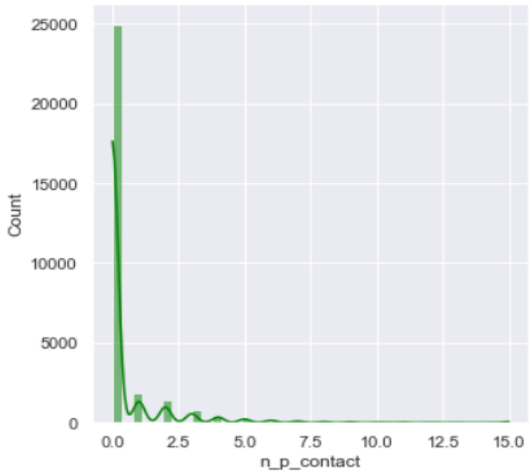

n_contact:

בניתוח של הגרף שעשינו ניתן לראות כי רוב מוחלט של הערכים הרלוונטיים לפיצ'ר זה קטנים מ 20.
רק ל 166 שורות יש ערך n_contact הגדול מ 20.
לכן החלטנו להמיר את כל הערכים שגדולים מ 20 לערך 20.
n_contact לאחר השינוי:

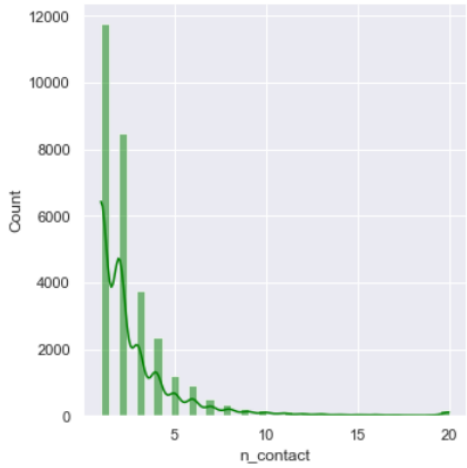

p_days:

בניתוח של הגרף שעשינו ניתן לראות כי רוב מוחלט של הערכים הרלוונטיים לפיצ'ר זה קטנים מ400, רק ל 168 שורות יש ערך הגדול מ 400.
לכן החלטנו להמיר את כל הערכים שגדולים מ400 (שזה 164 ערכים) לערך 400.
גרף p_days לאחר השינוי:

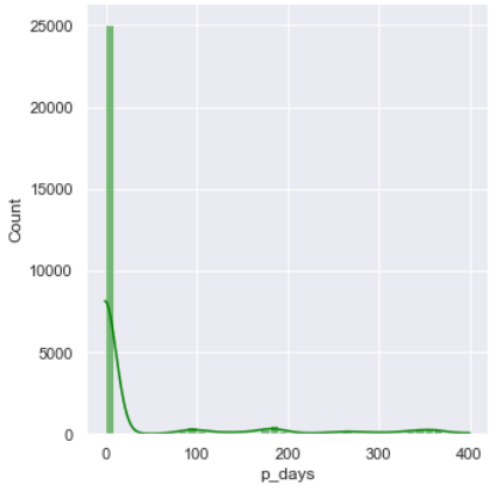

l_call_duration:

בניתוח של הגרף שעשינו ניתן לראות כי רוב מוחלט של הערכים הרלוונטיים לפיצ'ר זה קטנים מ1500, רק ל 95 מהערכים יש l_call_duration הגדול מ 1500.
לכן החלטנו להמיר את כל הערכים שגדולים מ 1500 לערך 1500.
גרף l_call_duration לאחר השינוי:

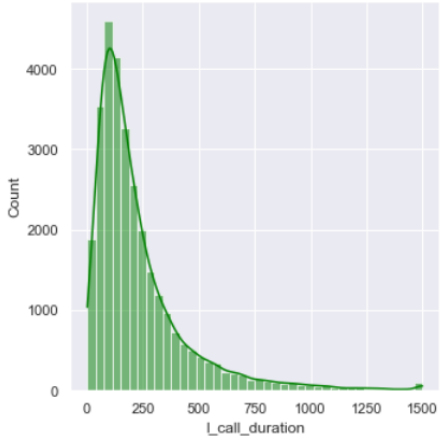

מחיקת פיצ'רים שלא תורמים מידע:

החלטנו למחוק עמודות שלא תורמות לנו מידע/המידע שהן מייצגות נמצא כבר בפיצ'רים האחרים ולכן ניתן לוותר עליהן:

- campaign_type – campain_tape זהה לכולם ולכן פיצ'ר זה לא רלוונטי.
- n_child – מחקנו פיצ'ר זה בתהליך ה pre processing.
- consent – פיצ'ר זה בקורלציה מלאה עם subscribed.

```
subscribed  consent
False       False      26997
True        True        3520
dtype: int64
```

לפי הבנתנו פיצ'ר זה מתאר שמי שרכש ביטוח, הסכים לרכוש ביטוח. אין בפיצ'ר זה ערך מוסף שניתן ללמוד על המשתתפים מדוע הם הסכימו לרכוש ביטוח, ואיך נדע לחזות בעתיד האם לקוח ירכוש בסוף ביטוח או לא ירכוש ביטוח.
גם מכיוון שיש 100% התאמה בין הרכישה להסכמה, ניתן לראות שההסכמה נבעה רגע לפי הרכישה, כלומר מילאו את העמודה הזו בעת הרכישה (יחד עם העמודה subscribed), לכן לא הרגשנו שיש טעם להשאיר את העמודה הזו.

שלב 5 - Data reduction

PCA

הרצנו את האלגוריתם PCA לצמצום המימדים.
בחרנו שה – n_components יהיה 0.999 כלומר אנחנו רצינו לשמר 99% מהשונות.
התוצאה שקיבלנו:

	0	1	2
0	-928.818493	-53.216928	259.982810
1	110.456134	91.328429	-13.639327
2	1602.954729	-168.625127	-50.290632
3	-699.128602	-183.322088	-0.030485
4	-2151.092535	-189.384820	-60.042958

שלב 6 - Data transformation

Discretization

בשלב זה החלטנו לחלק חלק מהפיצ'רים בעמודה חדשה המתארת את הפיצ'ר לפי קבוצות.
לדעתינו, יהיה יותר נוח להסתכל על ה data לפי קבוצות (עבור פיצ'רים מסויימים) כי כך יהיה יותר קל לנתח את ה data בהמשך.
הפיצרים שלהם החלטנו לחלק לפי קבוצות הן:

- profession
- age
- account_balance

והסיבה לכך היא שבפיצ'רים אלה יש התפלגות על הרבה ערכים, והיה נוח לחלקם אותם לפי קבוצות.

profession:

profession הוא פיצ'ר שהכיל הרבה ערכים, כ – 11 ערכים.
החלטנו ליצור פיצ'ר חדש שיתן לנו מידע קצת יותר מעניין.
לפיצ'ר זה קראנו isEmployed ויש לו 3 שדות:

- Employed.
- Unemployed.
- Student.

בעצם הפיצ'ר החדש מתאר לנו האם הלקוח עובד או לא עובד או סטודנט.
הצגת גרף isEmployed:

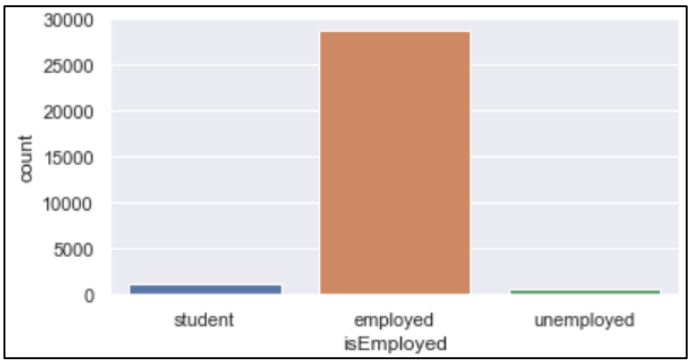

מהפיצ'ר החדש ניתן לראות שרוב הלקוחות אכן עובדים.

age:

החלטנו ליצור פיצ'ר חדש – age_bin.
בפיצ'ר זה חילקנו את age לקבוצות גיל:

קבוצת גיל	ערך
$age \leq 20$	0
$20 < age \leq 40$	1
$40 < age \leq 60$	2
$60 < age \leq 80$	3
$80 < age$	4

age_bin:

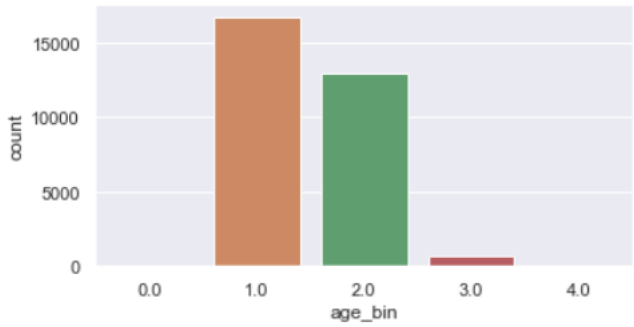

מהפיצ'ר החדש ניתן לראות שהקבוצת גיל הגבוהה ביותר היא בין 20 ל – 40.

account_balance:

החלטנו ליצור פיצ'ר חדש – account_balance_bin.
בפיצ'ר זה חילקנו את account_balance_bin לקבוצות משכורת:

קבוצת גיל	ערך
$\boldsymbol{account\ balance \leq 0}$	$\boldsymbol{-1}$
$\boldsymbol{0 < account\ balance \leq 1000}$	$\boldsymbol{1}$
$\boldsymbol{1000 < account\ balance \leq 5000}$	$\boldsymbol{2}$
$\boldsymbol{5000 < account\ balance \leq 10000}$	$\boldsymbol{3}$
$\boldsymbol{10000 < account\ balance}$	$\boldsymbol{4}$

account_balance_bin:

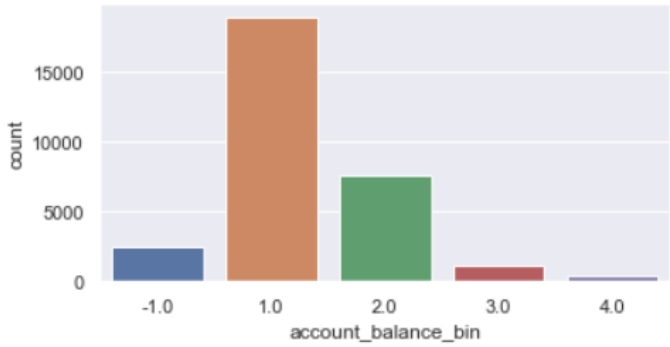

מהפיצ'ר החדש ניתן לראות שהמצב חשבון של רוב הלקוחות הוא בין 0 ל 1000.

רותם דאר – 311352934
יוגב יוסף – 312273410

MinMax normalization

בשלב זה בנינו עמודות נומריות חדשות מנורמלות בין 0 ל – 1.
הסיבה להוספת עמודות אלו היא שאם בהמשך יהיה לנו צורך בחישובי אלגוריתמים המתבססים על כך שה data הנומרי מתפלג על אותו ציר מספרים, אז נוכל להשתמש בעמודות מנורמלות אלה.
כמו כן נירמלנו את כל העמודות על פי אותו אלגוריתם – minmax.

העמודות החדשות מסומנות כ – xxxx_min_max כאשר xxxx הוא שם הפיצ'ר.

העמודות שנירמלנו הן:

age	status_cat
n_p_contact	education_Pre_Proc_cat
p_days	profession_Pre_Proc_cat
n_contact	device_Pre_Proc_cat
account_balance	month_l_date_cat
l_call_duration	p_outcome_Pre_Proc_cat

הצגת גרפים לאחר נרמול:

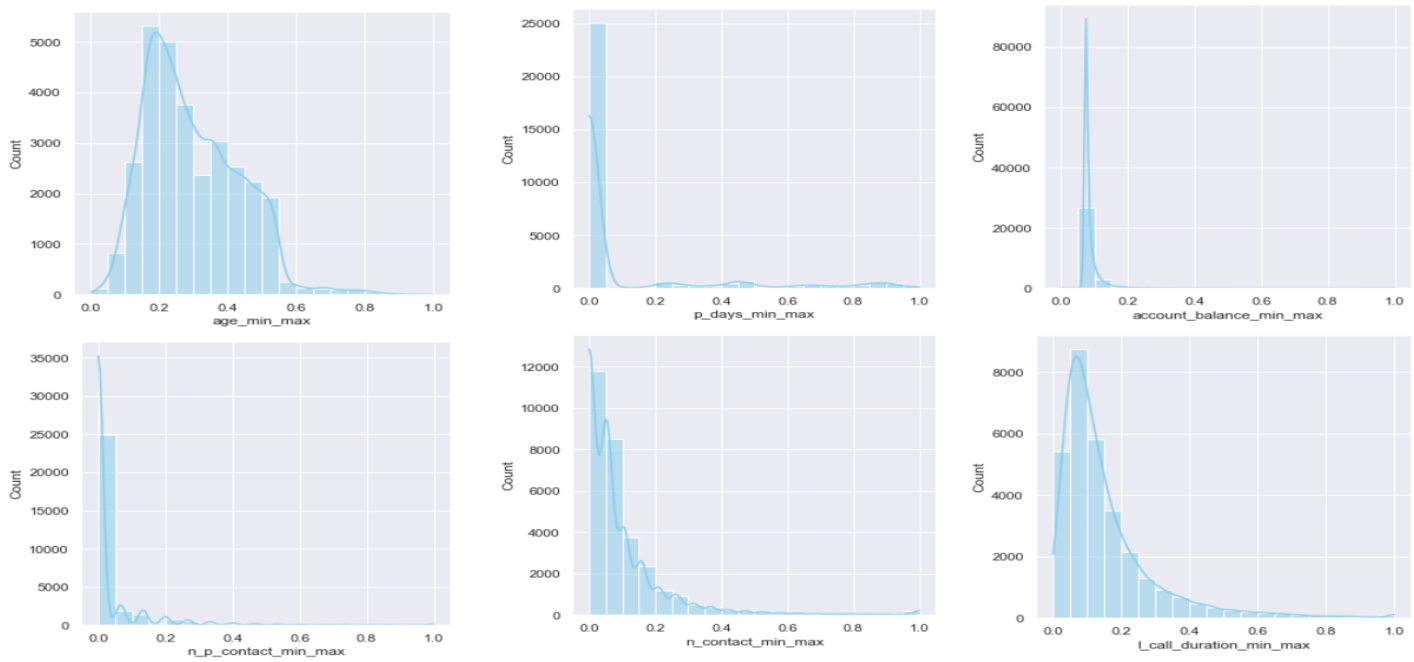

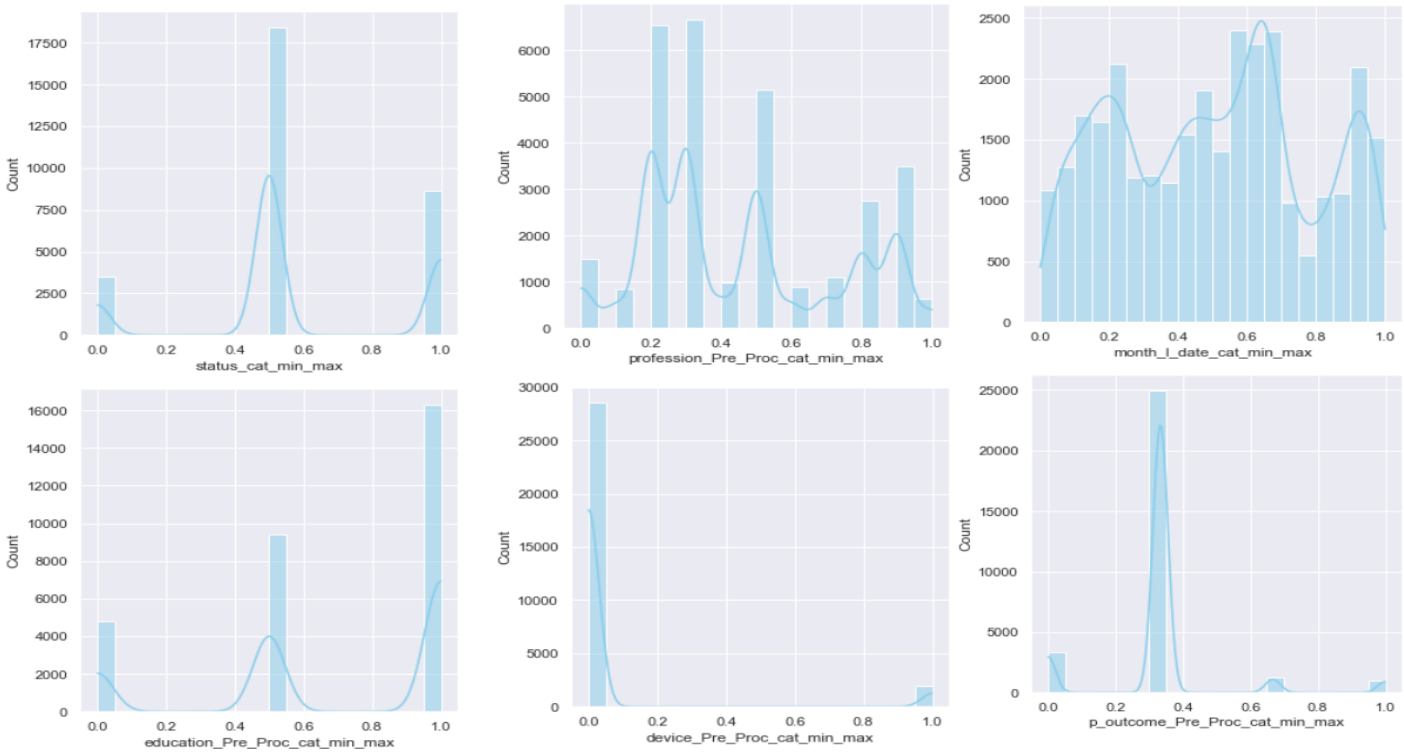

ניתן לראות שהטווח של הערכים השתנה בין 0 ל 1.
ובנוסף הגרפים ניראים בצורה דומה לגרפים המקוריים.